


1. Studium von Verteilungen

- Statistik ist die Wissenschaft der Daten
- Kategorische Daten (z.B. Mann/Frau)
 - Alternativ: Qualitative Daten
 - Numerische Daten (z.B. Einkommen)
 - Alternativ: Quantitative oder metrische Daten)

1.1 Diagramme für Verteilungen



- (Grob) symmetrisch: $\bar{x} \approx m$
- Linksschief: $\bar{x} < m$
- Rechtsschief: $\bar{x} > m$

1.2 Kennzahlen für Lage

Arithmetischer Mittelwert: $\bar{x}$

- Balance Punkt der Verteilung
- lin.trafo: $x_{i\text{neu}} = a + b(x_i)$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Median: m

- Verteilung 50 - 50
- sortierte Datenpunkte Min-Max
- Gerade Anzahl $n \rightarrow$ Mittelwert der beiden mittleren Datenpunkte
- Ungerade Anzahl $n \rightarrow$ mittleren Datenpunkt $\Rightarrow \frac{(n+1)}{2}$

Quartile:

- Q_1 trennt untere **25%** und obere **75%**
- Median = Q_2
- Q_3 trennt untere **75%** und obere **25%**

Perzentile:

- trennt untere $p\%$ und obere $(100-p)\%$
- Median = 50te Perzentil
- Alternative Bezeichnung (Quantil)

1.3 Kennzahlen für Streuung

Standardabweichung:

- typische Abweichung vom Mittelwert
- lin.trafo: $s_{\text{neu}} = |b| \cdot s$

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Varianz: (Stichprobe)

$$VAR = s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Varianz: (Grundgesamtheit)

$$VAR = s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Inter-Quartils-Abstand IQA:

- $IQA = Q_3 - Q_1$
- Robuster als die Standardabweichung
- 1.5 $\times$ IQA Regel:**

Ausreisser sind Datenpunkte

- kleiner als $Q_1 - 1.5 \times IQA$
- grösser als $Q_3 + 1.5 \times IQA$

Fünf-J-Kennzahlen Zusammenfassung:

- Min Q_1 m Q_3 Max

Boxplot:

- Zentrale Box reicht von Q_1 bis zu Q_3
- Linie innerhalb der Box markiert m
- Linien bis zu Punkten, die kein Ausreisser sind $Max: 1.5 \times IQA$
- Vergleich von Boxplot durch eine Aufreihung
- $\rightarrow$ Ev. Ausreisser erscheinen gesondert



2. Sammeln von Daten

2.1 Stichproben-Design:

- **Bevölkerung** - Gruppe der Individuen, für die wir Informationen wollen
- **Stichprobe** - Teil der Bevölkerung, von dem wir Informationen sammeln

Stichproben-Design: **Schlecht**

Ein Stichproben-Design ist **verzerrt**, wenn es bestimmte Segmente der Bevölkerung systematisch bevorzugt / benachteiligt

1. Die Freiwillige-Antwort Stichprobe:
 - Mitglieder der Stichprobe erwählen sich selbst
 - Extreme Meinungen (v.a. negativ) sind i.d.R. überpräsentiert
2. Die Ich-mach's-mir-leicht Stichprobe:
 - Stichproben, die einfach, angenehm und/oder billig sind
 - z.B. Umfrage in der Bibliothek

Stichproben-Design: **Gut**

Ein Stichproben-Design ist **unverzerrt**, wenn es keine Segmente der Bevölkerung systematisch bevorzugt / benachteiligt

- Klassische Methode: (Zufalls-Stichprobe)
- Ein Ball pro Mitglied der Bevölkerung
 - Ziehe n Bälle ohne zu schauen
 - $n \rightarrow$ Stichprobenumfang

2.2 Datenherkunft:

Beobachtungsdaten:

- Daten aus Beobachtungen / Befragungen von Individuen
- Die Reaktionen der Individuen wird in keiner Weise beeinflusst

Experimentelle Daten:

- Daten aus einem speziellen kontrollierten Experiment
- Verschiedene Gruppen (z.B. Medikament & Placebo)

In der VWL / BWL sind Beobachtungsdaten die Regel.

2.3 In Richtung statische Inferenz:

- **Parameter** ist eine Zahl, die die Bevölkerung beschreibt $\rightarrow$ unbekannt
- **Statistik** ist eine Zahl, die von einer Stichprobe berechnet wird

Verzerrung (Bias):

- Betrifft die Lage (das Zentrum) der Stichproben-Verteilung
- Falls die Lage gleich dem Parameter ist, der uns interessiert, dann ist der Schätzer **unverzerrt (unbiased)**

Variabilität:

- Betrifft die Streuung der Stichproben-Verteilung
- Je grösser n desto kleiner die Streuung

3. Wahrscheinlichkeitstheorie

3.1 Grundlagen:

Definitionen:

- **Zufallsexperiment** hat unvorhersehbare (aber wohldefinierte) Ergebnisse
- **Elementarereignisse** sind alle individuell möglichen Ergebnisse: s
- **Ergebnisraum** ist die Menge aller Elementarereignisse: S
- **Ereignis** ist eine Teilmenge des Ergebnisraums: A

Operationen:

- **Vereinigung:** A oder B treten ein $A \cup B = \{s : s \in A \text{ oder } s \in B\}$
- **Durchschnitt:** A und B treten ein $A \cap B = \{s : s \in A \text{ und } s \in B\}$
- **Komplementäreignis:** Tritt dann ein, wenn A nicht eintritt $A^c = \{s : s \notin A\}$

Eigenschaften:

- **Ausschöpfend:** $A \cup B = S$ Beispiel: $A \cup A^c = S$
- **Disjunkt:** $A \cap B = \emptyset$ Beispiel: $A \cap A^c = \emptyset$
- **Partition** eines Ereignisraums: Disjunkte Ereignisse, deren Vereinigung den gesamten Ereignisraum ausmacht

Axiome von Kolmogoroff:

Ereignis A ein Wert $P(A)$ zugeordnet

- $P(A) \geq 0$
 - $P(S) = 1$
 - $A \cap B = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B)$
- Regeln daraus:
- $0 \leq P(A) \leq 1$
 - $P(\emptyset) = 0$
 - $P(A^c) = 1 - P(A)$
 - $P(A) = \sum_{s \in A} P(s)$
 - $P(A) = P(A \cap B) + P(A \cap B^c)$
 - $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Unabhängigkeit:

- Zwei Ereignisse sind unabhängig, wenn gilt:
 - $P(A \cap B) = P(A) \times P(B)$
 - $P(A|B) = P(A|B^c)$

Multiplikations-Regel:

- Zwei Ereignisse sind unabhängig, wenn das Wissen, dass eines eintritt die Wahrscheinlichkeit, dass das andere eintritt nicht verändert
- es gilt: $P(A \cap B) = P(A) \times P(B)$

Bedingte Wahrscheinlichkeit:

- Es interessiert ein gewisses Ereignis A
- Wir wissen: Ereignis B ist eingetreten
- Wie ändert dieses Wissen die Wahrscheinlichkeit von A

Seien $A, B \subset S$ mit $P(B) > 0$. Dann ist die bedingte Wahrscheinlichkeit von A gegeben B definiert als.

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Satz von Bayes:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Nenner kann zerlegt werden (Partition) $\rightarrow P(B) = P(B \cap A) + P(B \cap A^c)$

- Regeln:
- Für bedingte Wahrscheinlichkeiten gelten die gleichen Regeln wie für normale Wahrscheinlichkeiten.

3.2 Zufallsvariablen:

Zufallsvariable (ZV) ist das numerische Ergebnis eines Zufallsexperiments X.

Direkt:

- Werfen eines Würfels $\Rightarrow$ Zahl

Indirekt:

- Werfen zweier Würfel $\Rightarrow$ Summe

Verteilung:

Die (Wahrscheinlichkeits-)Verteilung einer Zufallsvariablen X sagt uns, welche Werte X annehmen kann und wie wahrscheinlich diese Werte sind.

Diskrete Zufallsvariable

- Hat endlich viele oder abzählbar viele mögliche Ergebnisse
- $\Rightarrow$ Werfen eines Würfels

Stetige Zufallsvariable

- Kann jedes Ergebnis in einem Intervall annehmen
- $\Rightarrow$ Tagetemperatur

Verteilung einer diskreten Zufallsvariablen:

- Tabelle
- (Wahrscheinlichkeits-)Histogramm
- Formel $P(X = x_i) = p_i$
 - $p_i \geq 0$
 - $\sum_i p_i = 1$

Erwartungswert und Varianz:

Kennzahlen der Verteilung von X

- Erwartungswert: $E(X) = \mu_x$
- Varianz: $Var(X) = \sigma_x^2$

Erwartungswert:

Für diskrete Zufallsvariablen

- $\mu_x = \sum_i x_i p_i$
- $E(x^2) = \sum_i x_i^2 \times p_i$

Varianz:

Für diskrete Zufallsvariablen

- $\sigma_x^2 = \sum_i (x_i - \mu_x)^2 p_i$

Standardabweichung:

- $SA(X) = \sqrt{Var(X)}$
- Enthält gleiche Information wie Varianz, ist jedoch numerisch verschieden.

Gesetz der grossen Zahlen:

Wiederhole das Zufallsexperiment viele, viele Male. Halte alle Ergebnisse fest und betrachte ihre Gesamtheit als eine (grosse) Stichprobe.

- $\bar{x} \approx \mu_x$
- $s \approx \sigma_x$
- Histogramm gleicht Wahrscheinlichkeits-Histogramm von X

Regeln:

- $E(X + Y) = E(X) + E(Y)$
- $E(X - Y) = E(X) - E(Y)$
- Wenn X und Y unabhängig sind, $Var(X + Y) = Var(X) + Var(Y)$ $Var(X - Y) = Var(X) + Var(Y)$
- Mit zwei Konstanten
 - $E(a + bX) = a + bE(X)$
 - $Var(a + bX) = b^2 Var(X)$
 - $SA(a + bX) = |b|SA(X)$

Bernoulli-Verteilung: $X \sim \text{Bern}(p)$

Allgemeine Situation:

- Zwei mögliche Ergebnisse
 - Erfolg oder Misserfolg
 - Wahrscheinlichkeit eines Erfolges ist p
 - X ist die Anzahl der Erfolge
- | Ergebnis von X | 0 | 1 |
|--------------------|-------|---|
| Wahrscheinlichkeit | $1-p$ | p |
- $\mu_x = p$
 - $\sigma_x^2 = p(1-p)$ und $\sigma_x = \sqrt{p(1-p)}$

Binomial-Verteilung: $X \sim \text{Bin}(n, p)$

Allgemeine Situation:

- Zwei mögliche Ergebnisse
 - Erfolg oder Misserfolg
 - n Wiederholungen (unabhängig)
 - X ist die Anzahl der Erfolge in den n Versuchen
- | Ergebnis von X | 0 | 1 | ... | n |
|--------------------|---|---|-----|---|
| Wahrscheinlichkeit | ? | ? | ... | ? |
- $\mu_x = np$
 - $\sigma_x^2 = np(1-p)$ & $\sigma_x = \sqrt{np(1-p)}$
 - $P(X = 0) = (1-p)^n$ und $P(X = n) = p^n$

Binomial-Koeffizienten: TI: (nCr)

Anzahl der Sequenzen, die in k Erfolgen und n - k Misserfolgen resultieren. Nicht beachtet: Reihenfolge / Wiederholungen

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} = \frac{n \cdot (n-1) \cdot \dots \cdot (n-k+1)}{1 \cdot 2 \cdot \dots \cdot k}$$

- per Definition: $\binom{n}{0} = 1$
- Allgemeine Formel: $P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$

Poisson-Verteilung: $X \sim \text{Po}(\mu)$ oder $\text{Po}(\lambda)$

- Wenn Versuche nicht beobachtbar sind
- Mögliche Ergebnisse: 0, 1, 2, ...
- Wahrscheinlichkeiten

$$P(X = k) = e^{-\mu} \cdot \frac{\mu^k}{k!}$$

Summieren sich zu 1 auf:


$$\sum_{k=0}^{\infty} \frac{\mu^k}{k!} = e^{\mu}$$

- $\mu_x = \mu$ oder λ
- $\sigma_x^2 = \mu$ oder λ

Stetige Zufallsvariablen

- Dichte(funktion) $f(\cdot)$
- $f(x) \geq 0$ und $\int_{-\infty}^{\infty} f(x)dx = 1$
- W-keit = Fläche unter Dichtekurve
- $P(a \leq X \leq b) = P(a < X < b)$

Wahrscheinlichkeiten:



Erwartungswert und Varianz:

Für stetige Zufallsvariablen

- $\mu_x = E[x] = \int_{-\infty}^{\infty} x f(x) dx$
- Alternative Berechnung:
 - $Var(x) = E[x^2] - E[x]^2$
 - $E[x^2] = \int_{-\infty}^{\infty} x^2 f(x) dx$
 - $\sigma_x^2 = \int_{-\infty}^{\infty} (x - \mu_x)^2 f(x) dx$
 - $\sigma_x = \sqrt{\sigma_x^2}$

- Gesetz der Grossen Zahlen gilt analog
- $E(X)$ = Balance-Punkt der Dichte

Perzentile:

Das $p \times 100$ te Perzentil, x_p , einer stetigen Verteilung erfüllt die Bedingung:

- $P(X \leq x_p) = p = p \times 100\%$

Es löst folgende Gleichung:

$$\int_{-\infty}^{x_p} f(x) dx = p$$

Die Gleichverteilung: $X \sim U[a, b]$

- $f(x) = \begin{cases} \frac{1}{b-a} & \text{falls } a \leq x \leq b \\ 0 & \text{sonst} \end{cases}$
- W-keit = $\frac{1}{b-a} \times \text{Höhe} \times \text{Breite}$
- $\mu_x = \frac{a+b}{2}$
- $\sigma_x^2 = \frac{(b-a)^2}{12}$

Die Normalverteilung: $X \sim N(\mu, \sigma)$

- Dichte hat die Form einer Glockenkurve und ist bestimmt durch $\mu \geq 0$ (Länge) und $\sigma \geq 0$ (Streuung)

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}$$

- $\mu_x = \mu$
- $\sigma_x^2 = \sigma^2$

Die Standardisierung

$$X \sim N(\mu, \sigma) \Rightarrow \frac{X-\mu}{\sigma} \sim N(0, 1)$$

Transformation der Zufallsvariable, so dass:

- $\mu_x = 0$
- $\sigma_x^2 = 1$

Daher:

$$P(X < a) = P(\frac{X-\mu}{\sigma} < \frac{a-\mu}{\sigma}) = P(Z < \frac{a-\mu}{\sigma}) \rightarrow Z \sim N(0, 1)$$

Perzentile in der Normalverteilung

- Gegeben: $X \sim N(\mu, \sigma)$
- Gesucht: Perzentil x_p für $p \in (0, 1)$

$$\int_{-\infty}^{x_p} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2} dx = p$$

Methode:

$$p = P(Z < z_p) = P(\frac{X-\mu}{\sigma} < z_p) = P(X < \mu + \sigma z_p) \Rightarrow x_p = \mu + \sigma z_p$$

Die wichtigsten Perzentile von $N(0, 1)$:

z_p	0.90	0.95	0.975	0.99	0.995
z_p	1.282	1.645	1.960	2.326	2.576

3.3 Stichprobenverteilungen:

Allgemeine Situation:

- ZV mit Kennzahlen μ_x und σ_x > 0
- Zufallsexperiment wird n-mal wiederholt (unabhängig voneinander)
- Mittelwert $\bar{X}$ aus $\{X_1, X_2, \dots, X_n\}$
- $\bar{X}$ als neue Zufallsvariable betrachten

Bemerkung:

Da $\bar{X}$ von der Stichprobe $\{X_1, X_2, \dots, X_n\}$ berechnet wird, heisst diese Verteilung auch **Stichprobenverteilung**

Kennzahlen für die Verteilung von $\bar{X}$

- $E(\bar{X}) = \mu_x$
- $Var(\bar{X}) = \frac{\sigma_x^2}{n}$
- $SA(\bar{X}) = \frac{\sigma_x}{\sqrt{n}}$

Die gesamte Verteilung von $\bar{X}$ (fast...)

- Falls n gross $\rightarrow$ Verteilung gleicht einer Normalverteilung (Glockenkurve)
- Kennzahlen sind bekannt, es handelt sich um die Normalverteilung $\bar{X} \sim N(\mu_x, \frac{\sigma_x}{\sqrt{n}})$

Der Zentrale Grenzwertsatz (ZGS)

Je grösser der Stichprobenumfang n

- Verteilung von $\bar{X} \rightarrow$ Glockenkurve
- Streuung von $\bar{X}$ wird kleiner

Faustregel: für Normal-Approx. $n \geq 50$

$$\bar{X} \sim N(\mu_x, \frac{\sigma_x}{\sqrt{n}})$$

Der Zentrale Grenzwertsatz: Spezialfall

- Bezeichnung: $\hat{p}$ (Stichprobenanteil)
- Zugrunde liegendes Zufallsexperiment $\rightarrow$ Bernoulli
- daher
 - $\mu_x = p$
 - $\sigma_x = \sqrt{p(1-p)}$
- $\bar{X}$ ist der Anteil der Erfolge in den n Wiederholungen

$$\hat{p} \sim N\left(p, \sqrt{\frac{p(1-p)}{n}}\right)$$

Regel

- $Min\{np, n(1-p)\} \geq 10$

Äquivalente Approximation basiert auf der Stichproben-Anzahl der Erfolge

- Relation $X = np \rightarrow \sqrt{np(1-p)}$

Beide Approximationen führen zum identischen Ergebnis

Stp.-Umfang für gewünschte FM - Anteil

- KI für p mit vorgeg. Niveau $1 - \alpha$ und (höchstens) einer vorgeg. FM*
- Wie gross muss die Stichprobe (mindestens) sein?

$$n \geq \left(\frac{z_{1-\frac{\alpha}{2}}}{FM^*} \right)^2 p(1-p)$$

- Lösung hängt von Stichproben Anteil ab, aber unbekannt
- Schätzung für $\hat{p}$ einsetzen.
 - **worst case** $\hat{p} = 0.5$

KI für Differenz zweier Mittelwerte

Allgemeine Situation:

- Zwei Bevölkerungen. BV_1 und BV_2
 - Mittelwerte: μ_1 und μ_2
 - Varianzen: σ_1^2 und σ_2^2
- Uns interessiert die Diff. $\hat{\Delta} = \mu_1 - \mu_2$

Daten und Schätzer:

- Zwei unabhängige Zufallsstichproben: $X_1, X_2, \dots, X_{n1}$ und $Y_1, Y_2, \dots, Y_{n2}$
- Schätzer $= \bar{X} - \bar{Y}$

Kennzahlen des Schätzers:

- $E(\hat{\Delta}) = E(\bar{x} - \bar{y}) = E(\bar{x}) - E(\bar{y})$
 $= \mu_1 - \mu_2 \Rightarrow$ unverzerrt
- $Var(\hat{\Delta}) = Var(\bar{X} - \bar{Y})$
 $\stackrel{Unabh.}{=} Var(\bar{X}) + Var(\bar{Y}) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$

Wenn der Parameter $\Delta = \mu_1 - \mu_2$ ist, dann:

- Schätzer $= \bar{X} - \bar{Y}$

$$SA(\hat{\Delta}) = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

$$SF = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

- Das KI ist folglich:

$$(1 - \alpha)\% KI = \bar{X} - \bar{Y} \pm z_{1-\frac{\alpha}{2}} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Da ZGS: n_1 und $n_2 \geq 50$ **Datenpaare:**

- Wenn innerhalb eines Paares Abhängigkeit besteht, sind die Stichproben nicht mehr unabhängig
- $\bar{X}$ und $\bar{Y}$ nicht mehr unabhängig

Auswirkungen:

- $\hat{\Delta} = \bar{X} - \bar{Y}$ weiterhin der Schätzer
- Das KI funktioniert nicht mehr
 $\rightarrow$ *Falscher Standardfehler*

Trick:

- betrachte die paarweisen Differenzen $D_i = X_i - Y_i$
- Erwartungswert: $E(D_i) = E(X_i - Y_i) = \mu_1 - \mu_2$
- Das KI ist folglich:
 $(1 - \alpha)\% KI = \bar{D} \pm z_{1-\frac{\alpha}{2}} \times \frac{s_D}{\sqrt{n}}$

 $\bar{D}$ = Stp.-Mittelwert von $D_1, \dots, D_n$ s_D = Stp. SA von $D_1, \dots, D_n$ **KI für Differenz zweier Anteile**

Allgemeine Situation:

- Zwei Bevölkerungen. BV_1 und BV_2
 - Anteile: p_1 und p_2
- Uns interessiert die Diff. $\Delta = p_1 - p_2$

Daten und Schätzer:

- Zwei unabhängige Zufallsstichproben:
- Schätzer $= \hat{p} - \hat{p}$

Kennzahlen des Schätzers:

- $E(\hat{p}_1 - \hat{p}_2) = E(\hat{p}_1) - E(\hat{p}_2)$
 $= p_1 - p_2 \Rightarrow$ unverzerrt
- $Var(\hat{p}_1 - \hat{p}_2) \stackrel{Unabh.}{=} \frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}$

- Das KI ist folglich

$$\hat{p}_1 - \hat{p}_2 \pm z_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$$

Wir benötigen (ZGS):

- $Min\{n_1 \hat{p}_1, n_1(1 - \hat{p}_1)\} \geq 10$
- $Min\{n_2 \hat{p}_2, n_2(1 - \hat{p}_2)\} \geq 10$

4.2 Hypothesen-Tests:

Allgemeine Situation

- Ein *a priori* Wert μ_0 ist durch den Kontext gegeben
- Frage: $\mu = \mu_0$?

Wichtige Unterscheidung:

- Einseitiger Test: Wenn schon vor der Stichprobendurchführung bekannt, dass μ grösser (kleiner) als μ_0 ist
- Zweiseitiger Test: Wenn nicht bekannt ob μ grösser (kleiner) ist als μ_0

Interpretation:

- Der p -Wert misst Evidenz gegen H_0
- je kleiner der p -Wert, desto grösser Evidenz gegen H_0

Wir benötigen: $n \geq 50$ (ZGS)**Hypothesen-Test für Mittelwert μ** **Schritt 1**

Die Hypothesen aufstellen:

 $H_0 : \mu = \mu_0$ (Nullhypothese)

$$H_1 : \begin{cases} (a) & \mu > \mu_0 & (\text{rechtsseit.}) \\ (b) & \mu < \mu_0 & (\text{linksseit.}) \\ (c) & \mu \neq \mu_0 & (\text{zweiseitig}) \end{cases}$$

Schritt 2

Die Test-Statistik berechnen:

$$z = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

Schritt 3Den p -Wert berechnen: benötigen $n \geq 50$

$$PW = \begin{cases} (a) & P(Z \geq z) & (\text{rechtsseit.}) \\ (b) & P(Z \leq z) & (\text{linksseit.}) \\ (c) & 2P(Z \geq |z|) & (\text{zweiseitig}) \end{cases}$$

Alternativer Weg: H_0 verwerfen falls

$$\begin{cases} (a) & z \geq z_{1-\alpha} \\ (b) & z \leq -z_{1-\alpha} \\ (c) & |z| \geq z_{1-\frac{\alpha}{2}} \end{cases}$$

Gebräuchliche Trennpunkte:

$$PW \begin{cases} \leq 0.1 & : \text{milde Evidenz} \\ \leq 0.05 & : \text{anständige Evidenz} \\ \leq 0.01 & : \text{starke Evidenz} \end{cases}$$

1 - PW konfident, dass H_0 falsch

Signifikanzniveaus

$$PW \begin{cases} \leq \alpha & H_0 \rightarrow \text{verwerfen} \\ > \alpha & H_0 \rightarrow \text{nicht verwerfen} \end{cases}$$

Hypothesen-Test für Anteil p **Schritt 1**

Die Hypothesen aufstellen:

 $H_0 : p = p_0$ (Nullhypothese)

$$H_1 : \begin{cases} (a) & p > p_0 & (\text{rechtsseit.}) \\ (b) & p < p_0 & (\text{linksseit.}) \\ (c) & p \neq p_0 & (\text{zweiseitig}) \end{cases}$$

Schritt 2

Die Test-Statistik berechnen:

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

Schritt 3Den p -Wert berechnen:Benötigen: $Min\{np_0, n(1 - p_0)\} \geq 10$

$$PW = \begin{cases} (a) & P(Z \geq z) & (\text{rechtsseit.}) \\ (b) & P(Z \leq z) & (\text{linksseit.}) \\ (c) & 2P(Z \geq |z|) & (\text{zweiseitig}) \end{cases}$$

Hypo.-Test für Diff. zweier Mittelwerte**Schritt 1**

Die Hypothesen aufstellen:

 $H_0 : \Delta = \Delta_0$ (Nullhypothese)

$$H_1 : \begin{cases} (a) & \Delta > \Delta_0 & (\text{rechtsseit.}) \\ (b) & \Delta < \Delta_0 & (\text{linksseit.}) \\ (c) & \Delta \neq \Delta_0 & (\text{zweiseitig}) \end{cases}$$

Schritt 2

Die Test-Statistik berechnen:

Bei unabhängigen Zufalls-Stichproben:

$$z = \frac{\bar{X} - \bar{Y} - \Delta_0}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

oder bei Datenpaaren:

$$z = \frac{\bar{D} - \Delta_0}{s_D / \sqrt{n}}$$

Schritt 3Den p -Wert berechnen:Benötigen: $Min\{n_1, n_2\} \geq 50$

$$PW = \begin{cases} (a) & P(Z \geq z) & (\text{rechtsseit.}) \\ (b) & P(Z \leq z) & (\text{linksseit.}) \\ (c) & 2P(Z \geq |z|) & (\text{zweiseitig}) \end{cases}$$

Hypo.-Test für Diff. zweier Anteile**Schritt 1**

Die Hypothesen aufstellen:

 $H_0 : \Delta = \Delta_0$ (Nullhypothese)

$$H_1 : \begin{cases} (a) & \Delta > \Delta_0 & (\text{rechtsseit.}) \\ (b) & \Delta < \Delta_0 & (\text{linksseit.}) \\ (c) & \Delta \neq \Delta_0 & (\text{zweiseitig}) \end{cases}$$

Schritt 2

Die Test-Statistik berechnen:

Bei unabhängigen Zufalls-Stichproben:

$$z = \frac{\hat{p}_1 - \hat{p}_2 - \Delta_0}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}}$$

Schritt 3Den p -Wert berechnen: $Min\{n_1 \hat{p}_1, n_1(1 - \hat{p}_1), \text{etc.}\} \geq 10$

$$PW = \begin{cases} (a) & P(Z \geq z) & (\text{rechtsseit.}) \\ (b) & P(Z \leq z) & (\text{linksseit.}) \\ (c) & 2P(Z \geq |z|) & (\text{zweiseitig}) \end{cases}$$

Warnung!

- Grosse Stichprobenumfänge nötig
- Zufalls-Stichproben notwendig (z.B. Zeitreihen funktionieren nicht)

Die Güte eines Hypothesen-Tests

H_0	H_0 richtig	H_0 falsch
verwerf.	Typ I Fehler	Richtig
n. verw.	Richtig	Typ II Fehler

Signifikanz & Typ I Fehler

- gravierender als Typ II
- Das Signifik.niv. $\alpha = P(\text{Typ I Fehler})$

Güte & Typ II Fehler

- Def.: Güte = $1 - P(\text{Typ II Fehler})$

Faktoren der Güte

- Signifik.niv. α grösser $\rightarrow$ Güte besser
- Je weiter weg μ von $\mu_0 \rightarrow$ desto besser
- Std. Abw. $s \rightarrow$ je kleiner, desto besser
- Einseit. Test ist besser als zweiseitig
- Stp. Umfang $n \rightarrow$ grösser = besser

Berechnung einer Güte für Mittelwert

Zugrundeliegende Formel:

$$\bar{x}^* = \mu_0 - z_{1-\alpha} \times \frac{\sigma}{\sqrt{n}}$$

Schritt 1

- Richtigen Fall (a)(b)(c) auswählen

Schritt 2

- Wenn wird gewählter Fall verworfen

Schritt 3

- Fall (a) $\rightarrow$ **Rechtsseitig**

Güte = $P(z \geq z_{1-\alpha})$

$$\Leftrightarrow P\left(\frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \geq z_{1-\alpha}\right)$$

$$\Leftrightarrow P\left(\bar{X} \geq \frac{z_{1-\alpha} \times \sigma}{\sqrt{n}} + \mu_0\right)$$

ZGS benutzen:

$$P\left(Z \geq \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} + z_{1-\alpha}\right)$$

- Fall (b) $\rightarrow$ **Linksseitig**

Güte = $P(z \leq -z_{1-\alpha})$

$$\Leftrightarrow P\left(\frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \leq -z_{1-\alpha}\right)$$

$$\Leftrightarrow P\left(\bar{X} \leq \frac{-z_{1-\alpha} \times \sigma}{\sqrt{n}} + \mu_0\right)$$

ZGS benutzen:

$$P\left(Z \leq \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} - z_{1-\alpha}\right)$$

- Fall (c) $\rightarrow$ **Zweiseitig**

Güte = $P(z \leq -z_{1-\frac{\alpha}{2}})$

$$\dots$$

$$\dots$$

ZGS benutzen:

$$P\left(Z \leq \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} - z_{1-\frac{\alpha}{2}}\right)$$

Berechnung einer Güte für Anteil

Zugrundeliegende Formel:

$$\hat{p} = p_0 - z_{1-\alpha} \times \sqrt{\frac{p}{n}}$$

Schritt 1

- Richtigen Fall (a)(b)(c) auswählen

Schritt 2

- Wenn wird gewählter Fall verworfen

Schritt 3

- Fall (a) $\rightarrow$ **Rechtsseitig**

$$\hat{p} = p_0 + z_{1-\alpha} \times \sqrt{\frac{p_0(1-p_0)}{n}}$$

ZGS benutzen:

$$P\left(Z \geq \frac{(\hat{p} - p_A)}{\sqrt{p_A(1-p_A)/n}}\right)$$

- Fall (b) $\rightarrow$ **Linksseitig**

$$\hat{p} = p_0 - z_{1-\alpha} \times \sqrt{\frac{p_0(1-p_0)}{n}}$$

ZGS benutzen:

$$P\left(Z \leq \frac{(\hat{p} - p_A)}{\sqrt{p_A(1-p_A)/n}}\right)$$

- Fall (c) $\rightarrow$ **Zweiseitig**

$$P\left(Z \leq \frac{(\hat{p}_1 - p_A)}{\sqrt{p_A(1-p_A)/n}} + \frac{(\hat{p}_2 - p_A)}{\sqrt{p_A(1-p_A)/n}}\right)$$

4.3 Inferenz in Kontingenz-Tabellen

Allgemeine Situation:

- Zwei kategorische Variablen X und Y
- Beziehung zwischen X und Y ?

Schritt 1

Die Hypothesen aufstellen:

- H_0 : X und Y sind unabhängig
- H_1 : X und Y sind abhängig

Schritt 2

Die Test-Statistik berechnen:

- Marginale Wahrscheinlichkeiten durch die Stichproben-Anteile schätzen

- Allgemein: $e_{ij} = \frac{(h_{i.} \times h_{.j})}{n}$
 - Chi-Quadrat Test-Statistik
- $$\chi^2 = \sum_{\text{Zellen}} \frac{(\text{Beobachtet} - \text{Erwartet})^2}{\text{Erwartet}}$$

Schritt 3Den p -Wert berechnen:

$$P(\chi_{1-\alpha, (r-1)(s-1)}^2 \geq X^2)$$

- kritischer Wert $\chi_{1-\alpha, (r-1)(s-1)}^2$ in Tabelle nachschauen

- Freiheitsgrade: $k = (r - 1)(s - 1)$

 H_0 verwerfen, falls

- $PW \leq \alpha$
- $X^2 \geq \chi_{1-\alpha, (r-1)(s-1)}^2$

 χ^2 tief $\rightarrow X$ und Y unabhängig χ^2 hoch $\rightarrow H_0$ nicht verwerfen $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein $\chi^2 = 0 \rightarrow$ Spezialfall, Tabellen stimmen überein